BSG Project – Pipeline inmobiliario en GCP con GCS, Data Fusion y BigQuery

Contenido

1. Definición del enfoque del proyecto 2
2. Creación del repositorio 2
3. Inicialización de Git 3
4. Generación de datasets 4
5. Creación del proyecto en GCP 5
6. Creación del Data Lake 6
7. Carga de archivos 6
8. Creación de dataset en BigQuery 7
9. Creación de instancia en Data Fusion 7
10. Creación del pipeline 8
11. Manejo de errores 8
12. Ejecución del pipeline 9
13. Validación 9
14. Documentación 10

1. Definición del enfoque del proyecto

Se decidió desarrollar un MVP (mínimo viable) con un enfoque inmobiliario, simulando integración entre Oracle ERP y Salesforce CRM. Se utilizaron archivos simulados y servicios de GCP: GCS como Data Lake, Data Fusion como ETL y BigQuery como Data Warehouse.

2. Creación del repositorio

Se creó el repositorio 'bsg-project' con estructura:

- data/

- docs/

- sql/

- datafusion/

Incluyendo README.md

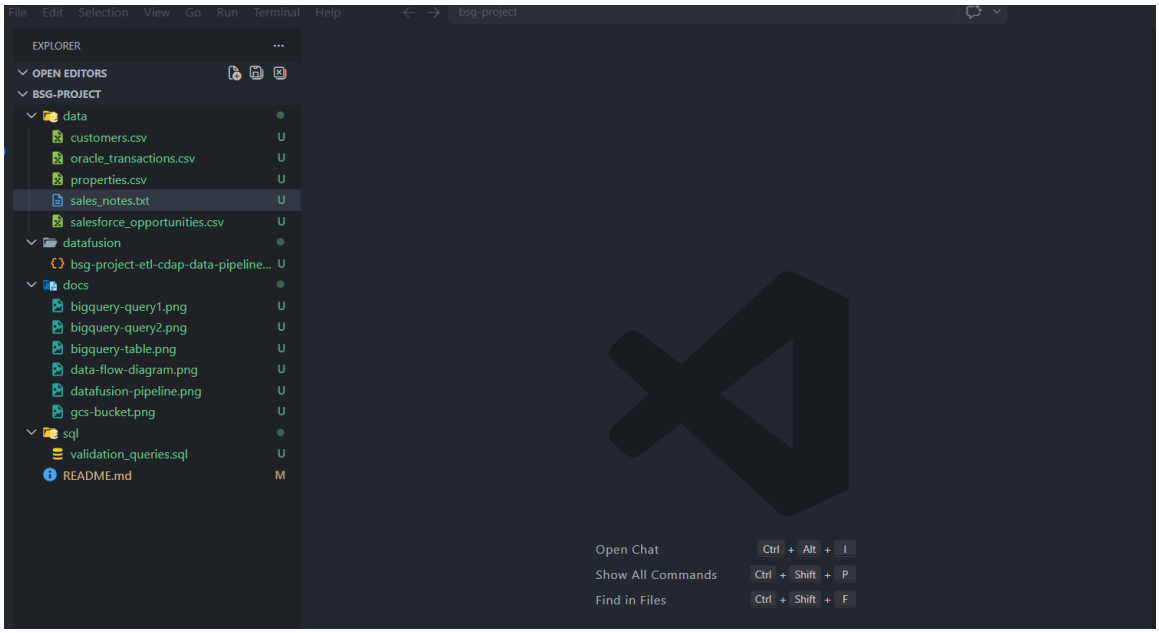

3. Inicialización de Git

Se inicializó Git, se hizo commit inicial y se conectó con GitHub.

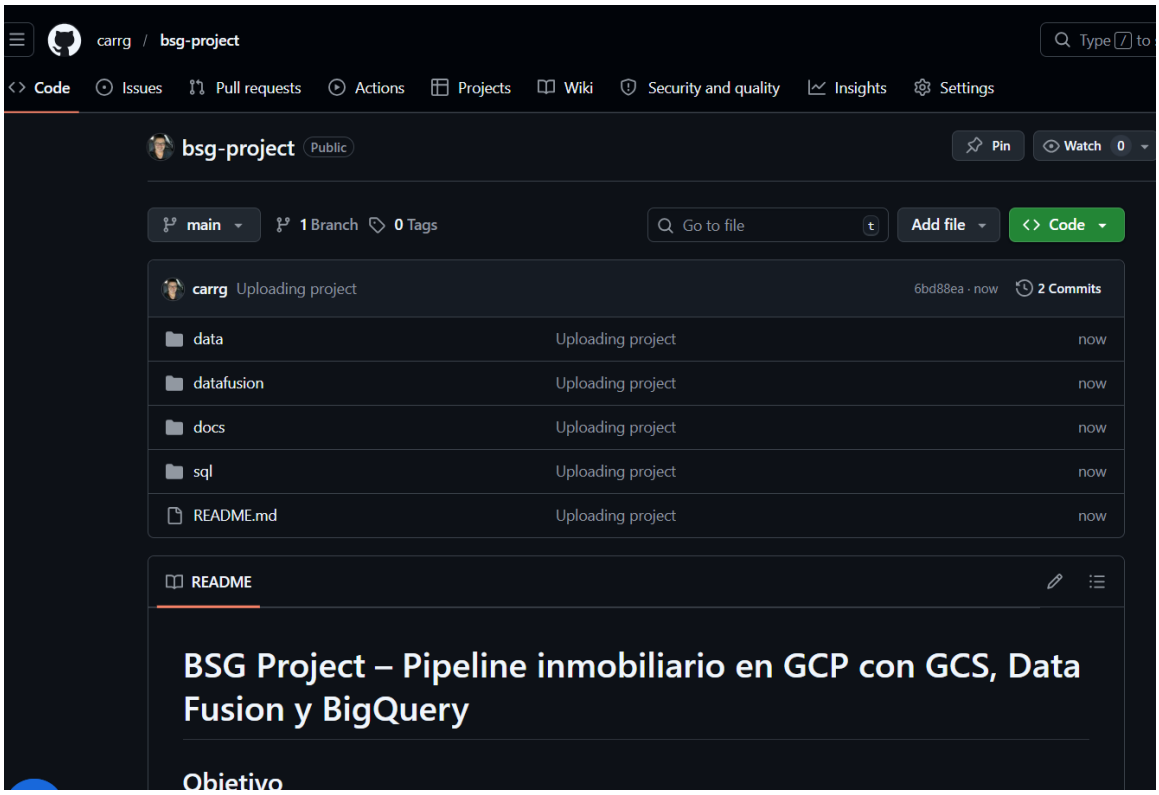

4. Generación de datasets

Se crearon archivos CSV y TXT simulando:

- clientes

- propiedades

- oportunidades

- transacciones

- notas

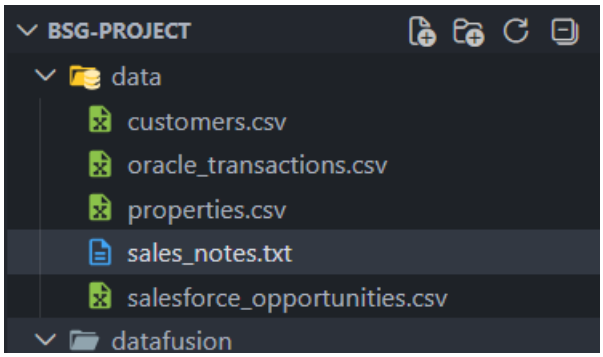

5. Creación del proyecto en GCP

Se creó el proyecto y se habilitaron APIs de:

- Cloud Storage

- BigQuery

- Data Fusion

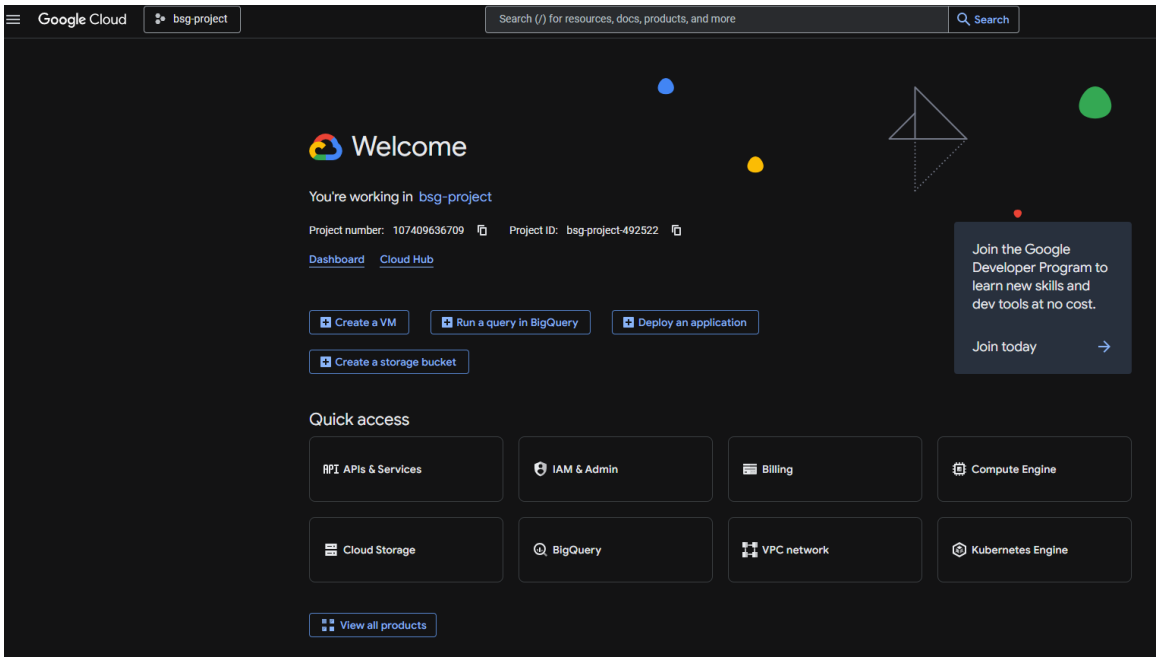

6. Creación del Data Lake

Se creó un bucket en GCS con estructura:

- raw/

- processed/

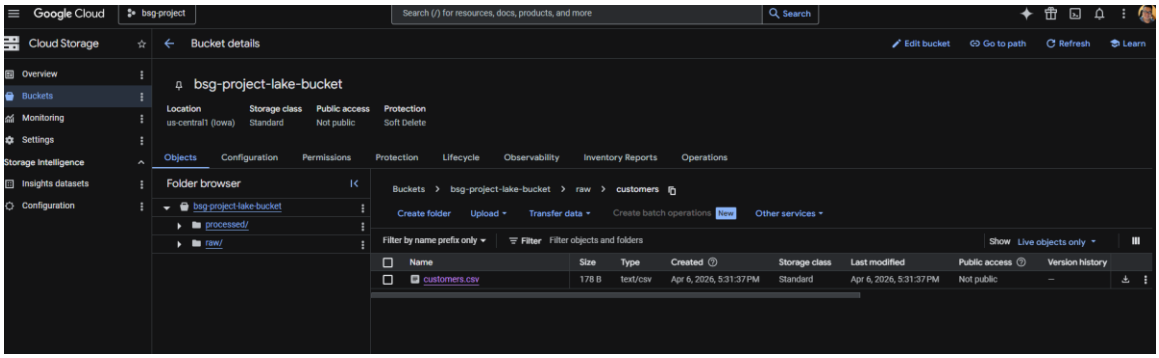

7. Carga de archivos

Se subieron los archivos a carpetas dentro de raw/.

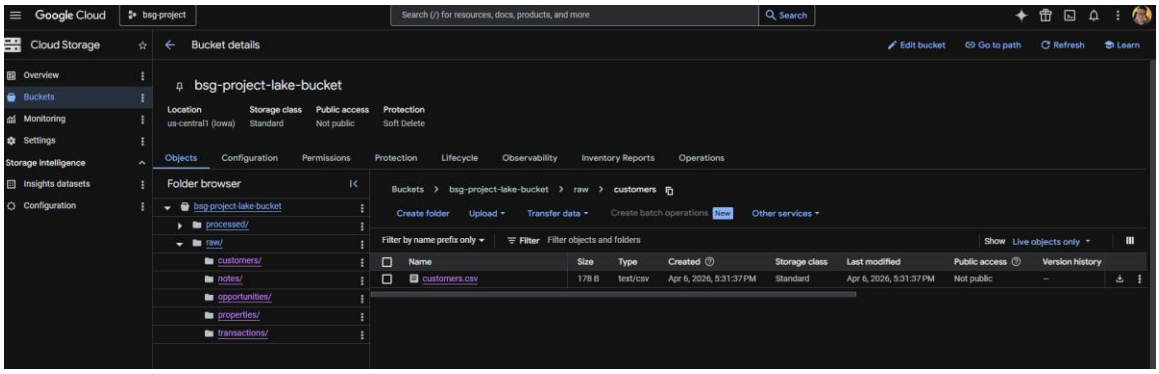

8. Creación de dataset en BigQuery

Se creó el dataset: bsg_project_dw.

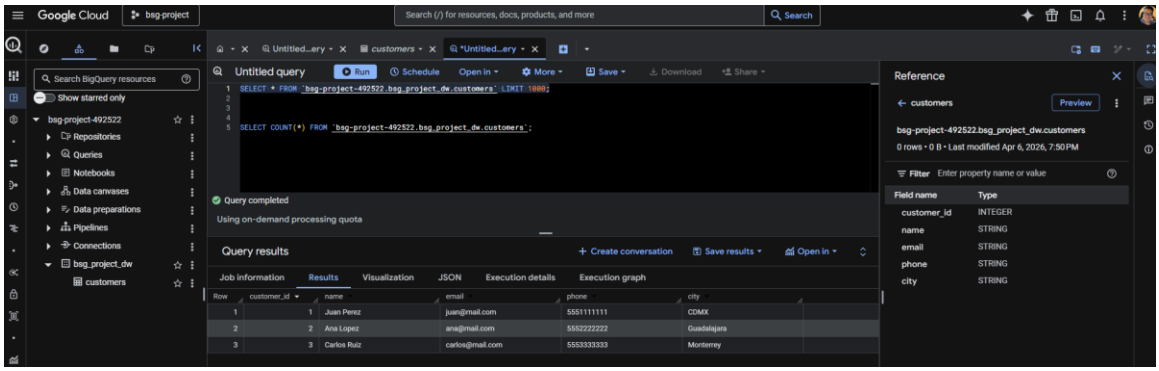

9. Creación de instancia en Data Fusion

Se creó una instancia básica en us-central1.

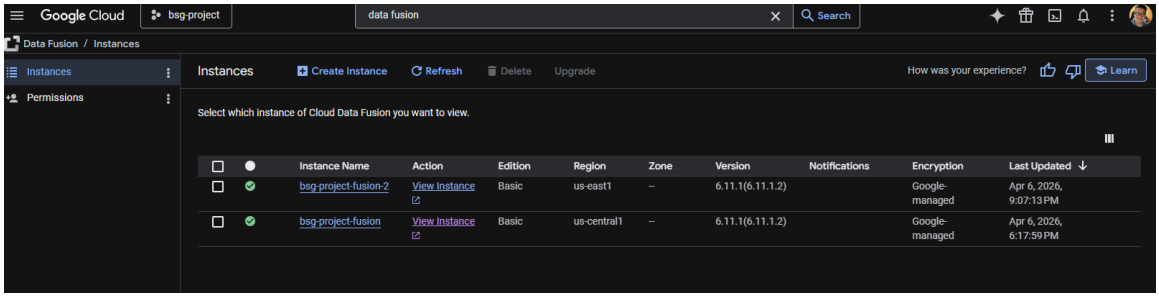

10. Creación del pipeline

Se configuró pipeline tipo batch:

- GCS → Transformación → BigQuery
- Se configuró lectura CSV con schema correcto.
- Se utilizó componente Projection para transformación básica.
- Se configuró tabla destino en BigQuery con escritura tipo truncate.

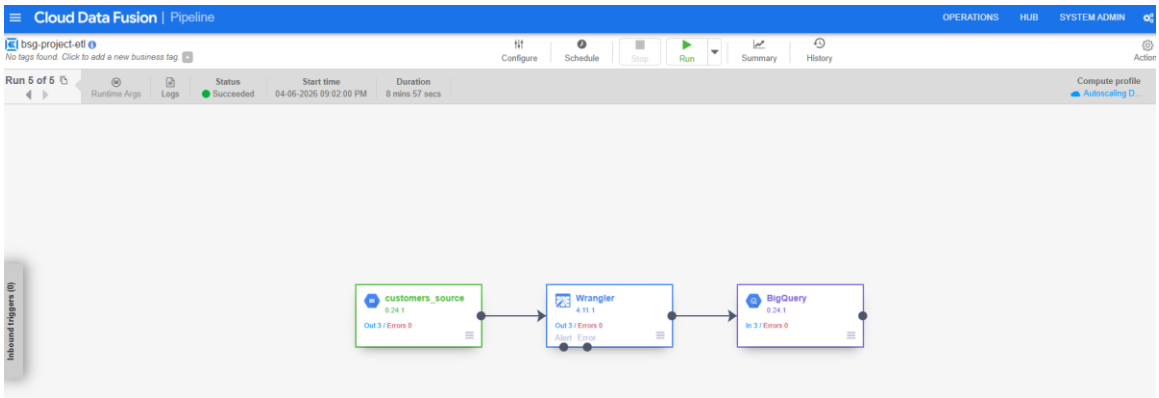

11. Manejo de errores

Se resolvieron errores de:

- schema CSV

- tipos de datos (uso de STRING)

- cuotas de Dataproc

12. Ejecución del pipeline

El pipeline se ejecutó correctamente cargando datos a BigQuery.

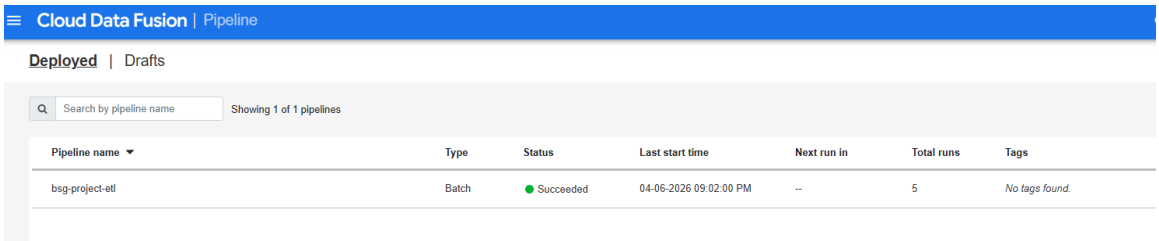

13. Validación

Se ejecutaron queries SQL para validar datos.

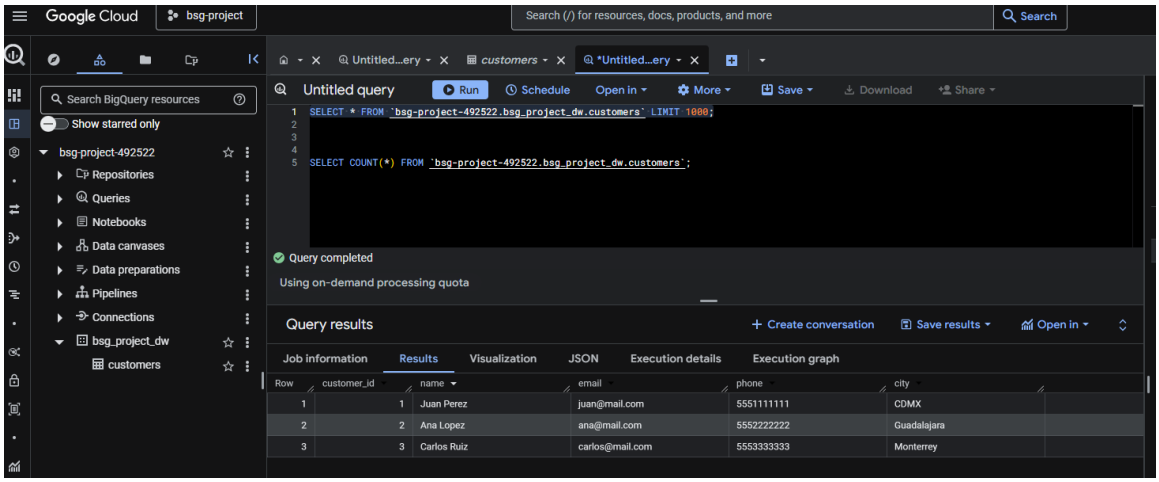

14. Documentación

Se creó README, SQL queries, JSON del pipeline y diagrama.

Se agregó el video el carpeta docs

19. Resultado

Se logró un pipeline funcional end-to-end con:

- Data Lake (GCS)
- ETL (Data Fusion)
- Data Warehouse (BigQuery)